PROYECTO: NAIVE BAYES CON ESTIMACIÓN KDE PARA MANTENIMIENTO PREDICTIVO

PROF. MANUEL CERÓN

INTEGRANTES:
PAOLA VALDES
MARCOS MARTINEZ
MANUE GÓNDOLA

11/03/2026

INTRODUCCION

Mantenimiento Predictivo
Permite:
- Anticipar fallas en máquinas
- Analizar datos de sensores
- Reducir costos de mantenimiento

Utiliza técnicas de Machine Learning

DATASET

	UDI	Product ID	Type	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	TWF	HDF	PWF	OSF	RNF
0	1	M14860	M	298.1	308.6	1551	42.8	0	0	0	0	0	0	0
1	2	L47181	L	298.2	308.7	1408	46.3	3	0	0	0	0	0	0
2	3	L47182	L	298.1	308.5	1498	49.4	5	0	0	0	0	0	0
3	4	L47183	L	298.2	308.6	1433	39.5	7	0	0	0	0	0	0
4	5	L47184	L	298.2	308.7	1408	40.0	9	0	0	0	0	0	0

Dataset utilizado

AI4I 2020 Predictive Maintenance

Contiene:

- 10,000 registros
- 14 variables

Ejemplos de sensores:

- Air temperature
- Process temperature
- Rotational speed
- Torque
- Tool wear

	0
UDI	0
Product ID	0
Type	0
Air temperature [K]	0
Process temperature [K]	0
Rotational speed [rpm]	0
Torque [Nm]	0
Tool wear [min]	0
Machine failure	0
TWF	0
HDF	0
PWF	0
OSF	0
RNF	0

EXPLORACIÓN DE DATOS

Distribución de fallas

Máquinas sin falla: 9661

Máquinas con falla: 339

Problema:

⚠ Dataset desbalanceado

Métrica utilizada:

AUC ROC

Análisis exploratorio de datos

Se analizaron variables como:

- Torque
- Tool wear
- Temperaturas

Objetivo:

Identificar patrones entre máquinas que fallan y las que no.

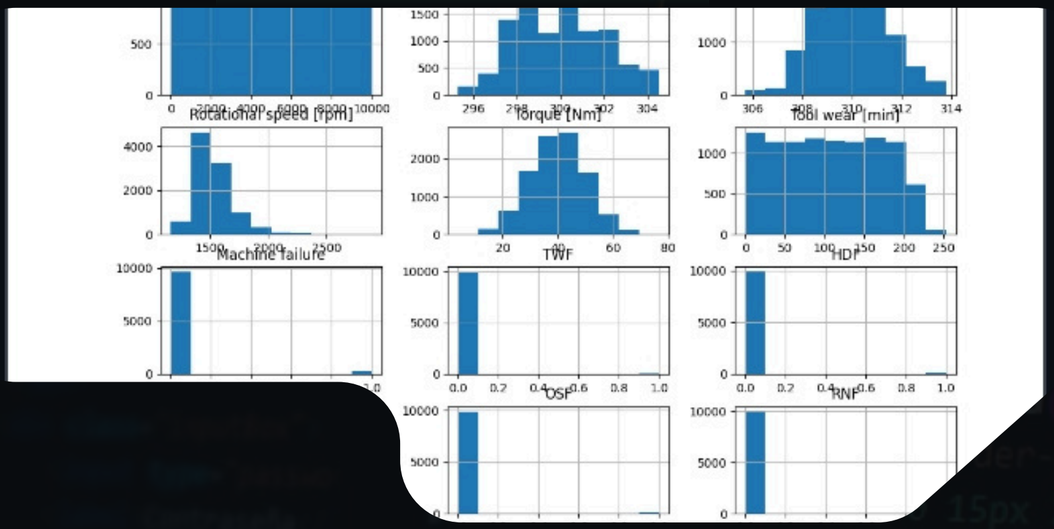

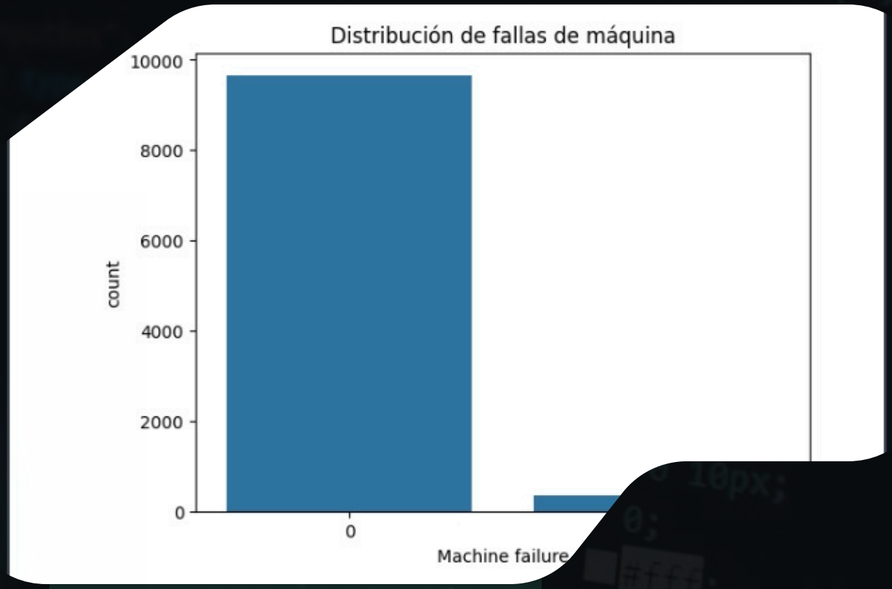

DESBALANCE DE CLASES

PREPROCESAMIENTO

Preprocesamiento de datos

1. Eliminación de columnas irrelevantes
2. Conversión de variables categóricas
3. Estandarización de datos

Herramienta utilizada:

StandardScaler

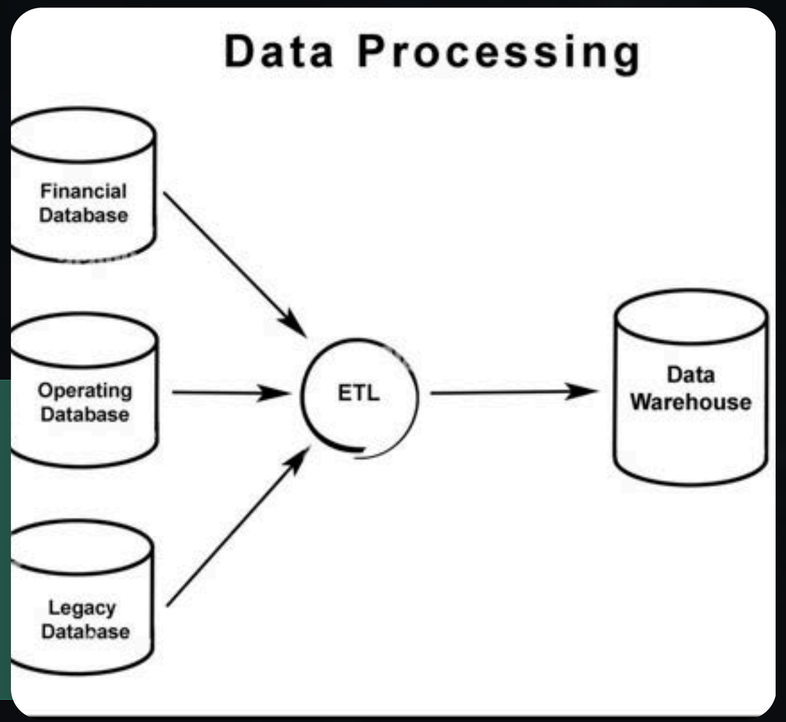

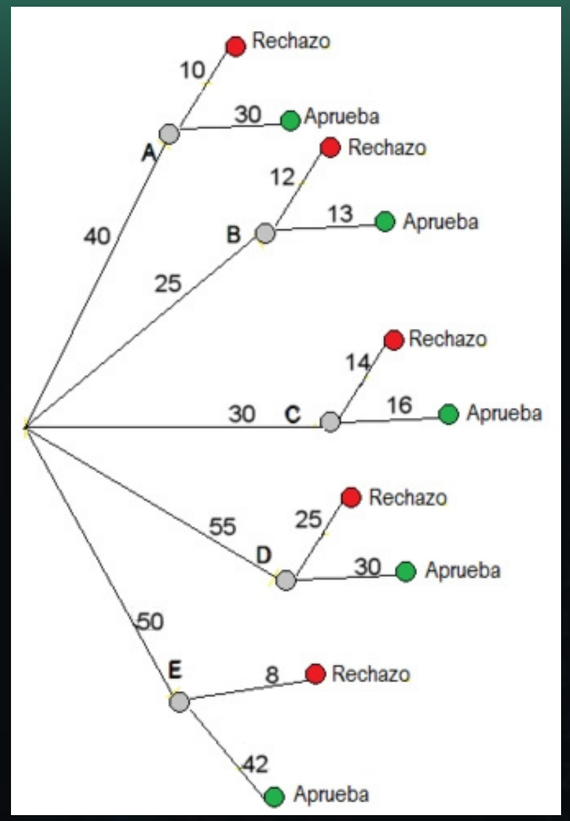

Modelo utilizado:

Gaussian Naive Bayes

Características:

- Modelo probabilístico
- Basado en el teorema de Bayes
- Asume distribución normal

MODELO BASELINE

EVALUACIÓN DEL MODELO

Evaluación del modelo

Método:

Stratified Cross Validation

5 folds

Resultado:

AUC ≈ 0.985

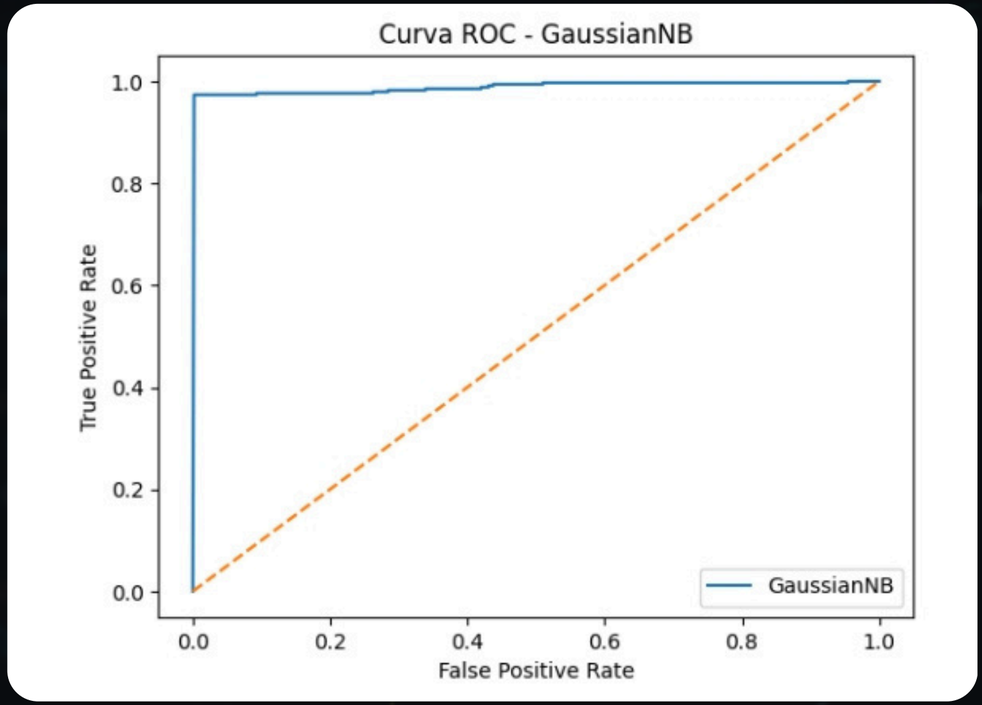

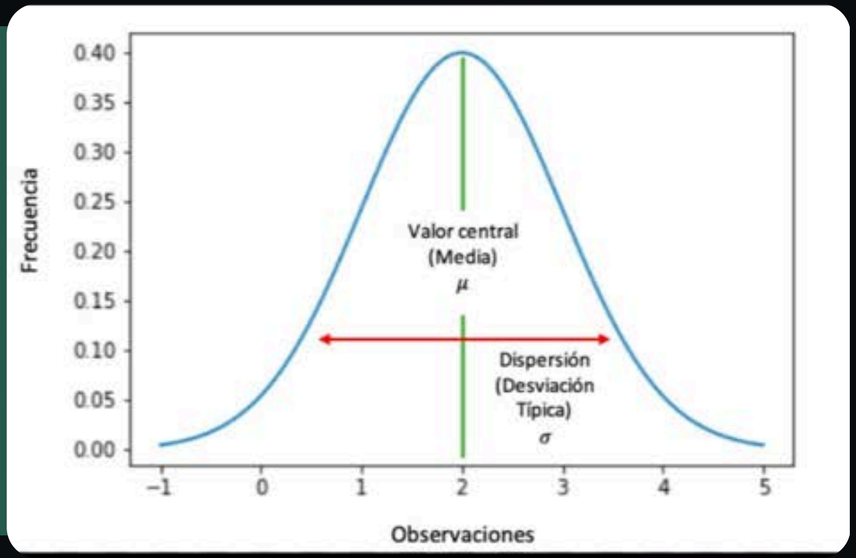

PROBLEMA DEL MODELO GAUSSIANO

Limitación de Gaussian Naive Bayes

Asume:

Distribuciones normales

Pero en datasets reales:

Las variables no siempre son gaussianas

Solución:

Kernel Density Estimation

KDE

Kernel Density Estimation (KDE)

Permite:

- Estimar densidades de probabilidad
- Sin asumir distribución específica

Modelos evaluados:

- KDE Gaussiano
- KDE Silverman
- KDE Parzen

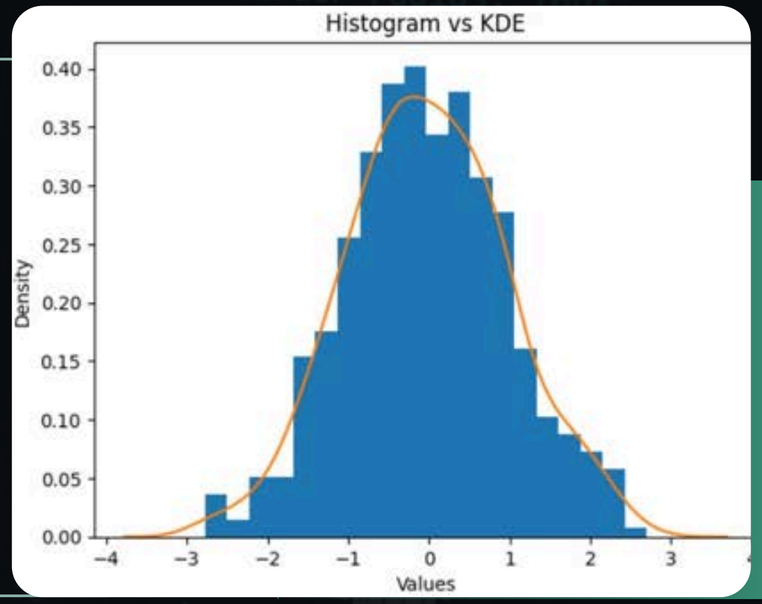

RESULTADOS

COMPARACIÓN DE MODELOS

GAUSSIANNB → 0.985
KDE GAUSSIANO → 0.991
KDE SILVERMAN → 0.991
KDE PARZEN → 0.996

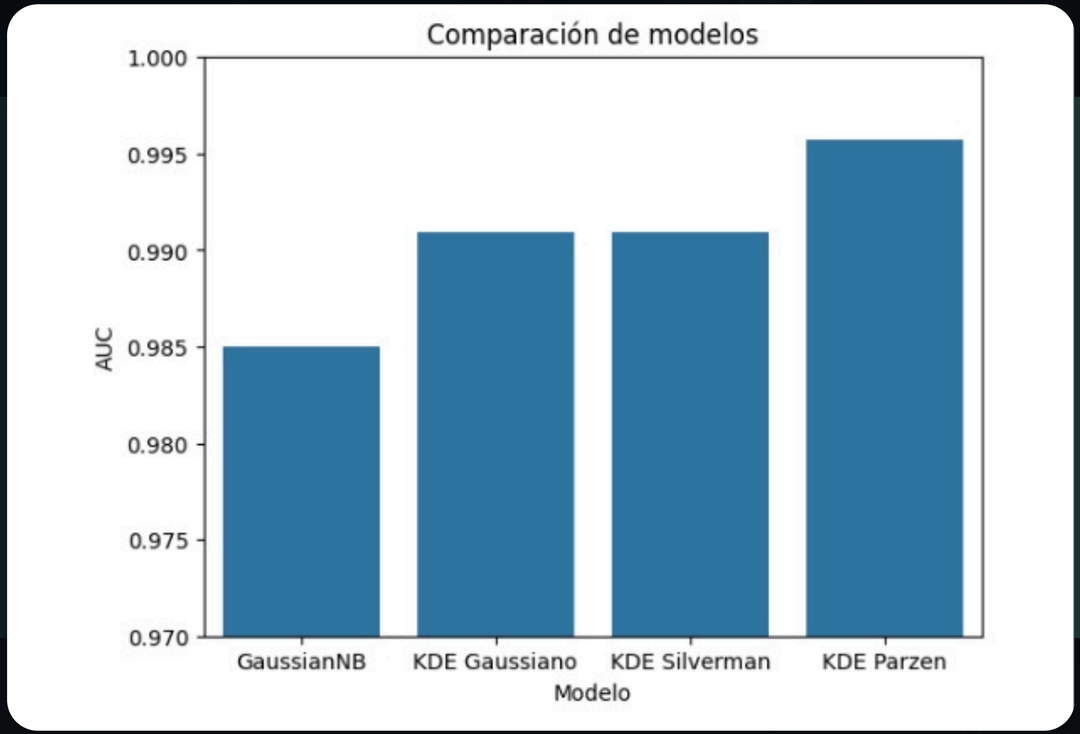

CONCLUSIÓN

- KDE mejora el desempeño del modelo
- GaussianNB funciona bien como baseline
- El mejor modelo fue KDE Parzen

Resultado final:
AUC ≈ 0.996

REFERENCIAS

AI4I 2020 Predictive Maintenance Dataset, UCI Machine Learning Repository, 2020.

Pattern Recognition and Machine Learning, C. M. Bishop, Springer, 2006.

The Elements of Statistical Learning, T. Hastie, R. Tibshirani, J. Friedman, Springer, 2009.

Scikit-learn Documentation, https://scikit-learn.org

THANK YOU