PROYECTO: NAIVE BAYES CON ESTIMACIÓN KDE PARA MANTENIMIENTO PREDICTIVO

PROF. MANUEL CERÓN

INTEGRANTES:
PAOLA VALDES
MARCOS MARTINEZ
MANUE GÓNDOLA

11/03/2026

INTRODUCCION

Mantenimiento Predictivo
Permite:
- Anticipar fallas en máquinas
- Analizar datos de sensores
- Reducir costos de mantenimiento

Utiliza técnicas de Machine Learning

DATASET

	UDI	Product ID	Type	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	TWF	HDF	PWF	OSF	RNF
0	1	M14860	M	298.1	308.6	1551	42.8	0	0	0	0	0	0	0
1	2	L47181	L	298.2	308.7	1408	46.3	3	0	0	0	0	0	0
2	3	L47182	L	298.1	308.5	1498	49.4	5	0	0	0	0	0	0
3	4	L47183	L	298.2	308.6	1433	39.5	7	0	0	0	0	0	0
4	5	L47184	L	298.2	308.7	1408	40.0	9	0	0	0	0	0	0

Dataset utilizado

AI4I 2020 Predictive Maintenance

Contiene:

- 10,000 registros
- 14 variables

Ejemplos de sensores:

- Air temperature
- Process temperature
- Rotational speed
- Torque
- Tool wear

	0
UDI	0
Product ID	0
Type	0
Air temperature [K]	0
Process temperature [K]	0
Rotational speed [rpm]	0
Torque [Nm]	0
Tool wear [min]	0
Machine failure	0
TWF	0
HDF	0
PWF	0
OSF	0
RNF	0

EXPLORACIÓN DE DATOS

Distribución de fallas

Máquinas sin falla: 9661

Máquinas con falla: 339

Problema:

⚠ Dataset desbalanceado

Métrica utilizada:

AUC ROC

Análisis exploratorio de datos

Se analizaron variables como:

- Torque
- Tool wear
- Temperaturas

Objetivo:

Identificar patrones entre máquinas que fallan y las que no.

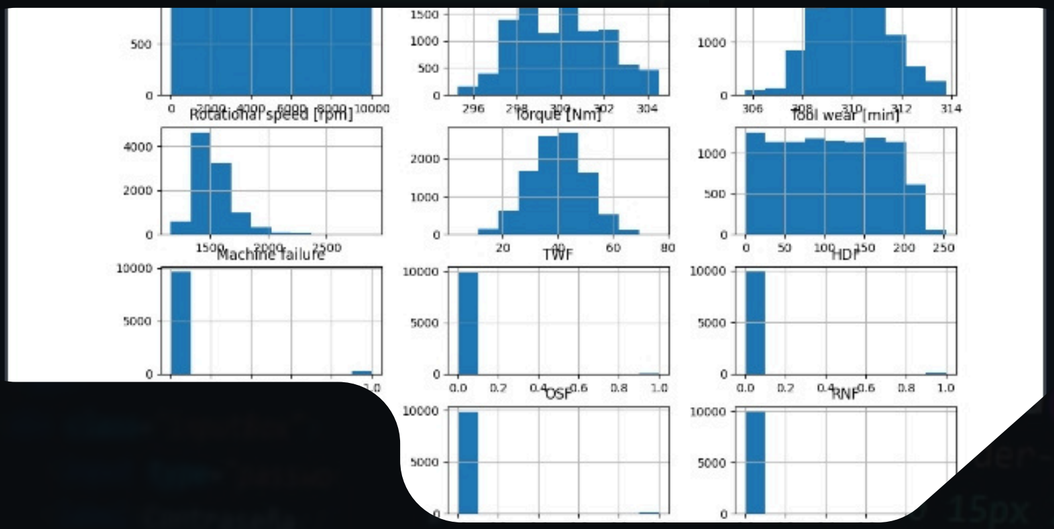

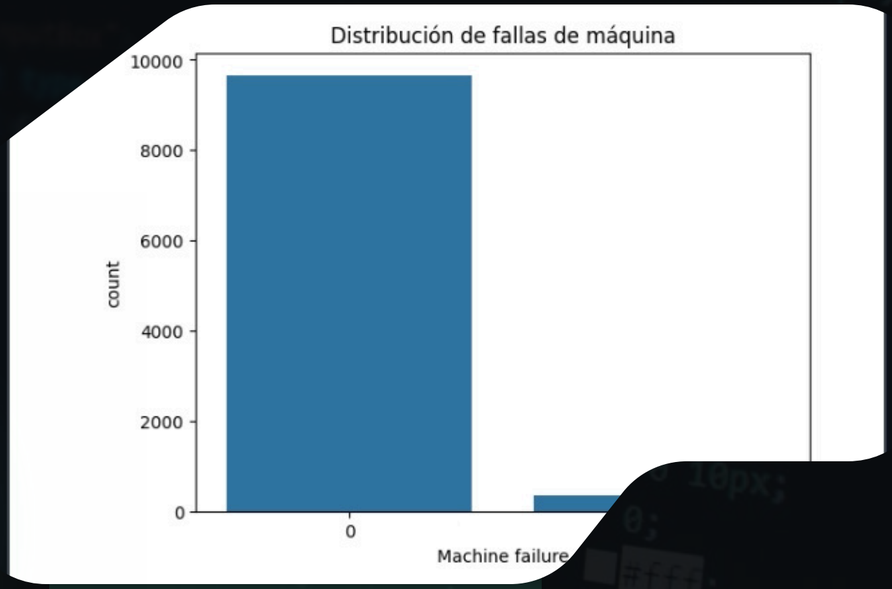

DESBALANCE DE CLASES

PREPROCESAMIENTO

Preprocesamiento de datos

1. Eliminación de columnas irrelevantes
2. Conversión de variables categóricas
3. Estandarización de datos

Herramienta utilizada:

StandardScaler

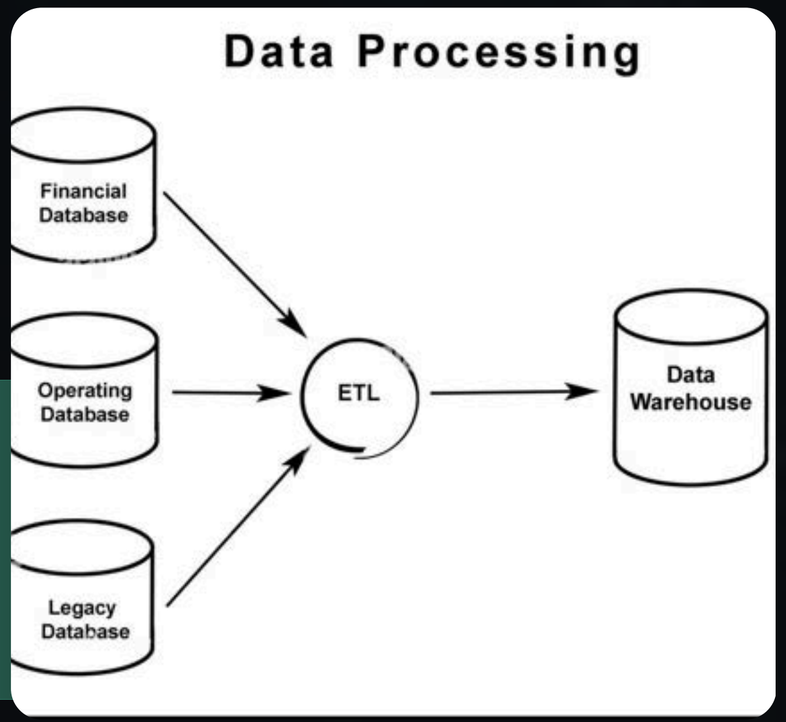

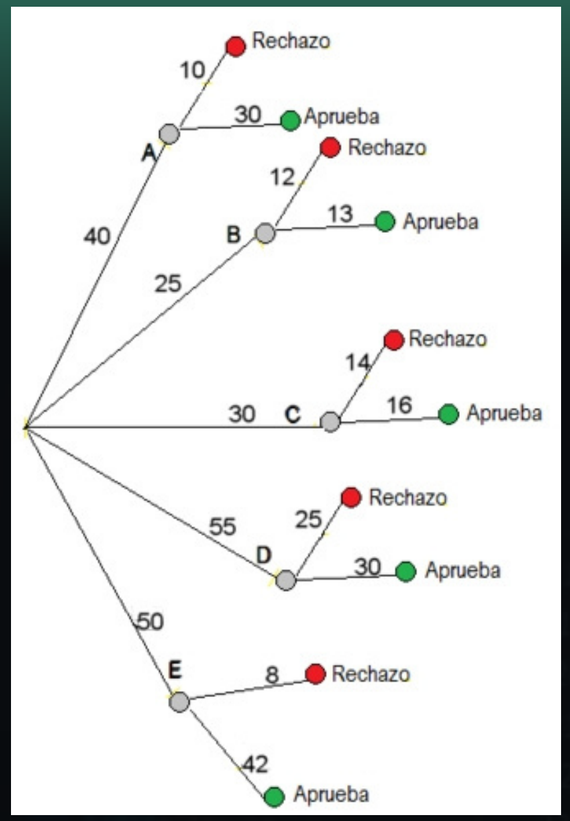

Modelo utilizado:

Gaussian Naive Bayes

Características:

- Modelo probabilístico
- Basado en el teorema de Bayes
- Asume distribución normal

MODELO BASELINE

EVALUACIÓN DEL MODELO

Evaluación del modelo

Método:

Stratified Cross Validation

5 folds

Resultado:

AUC ≈ 0.985

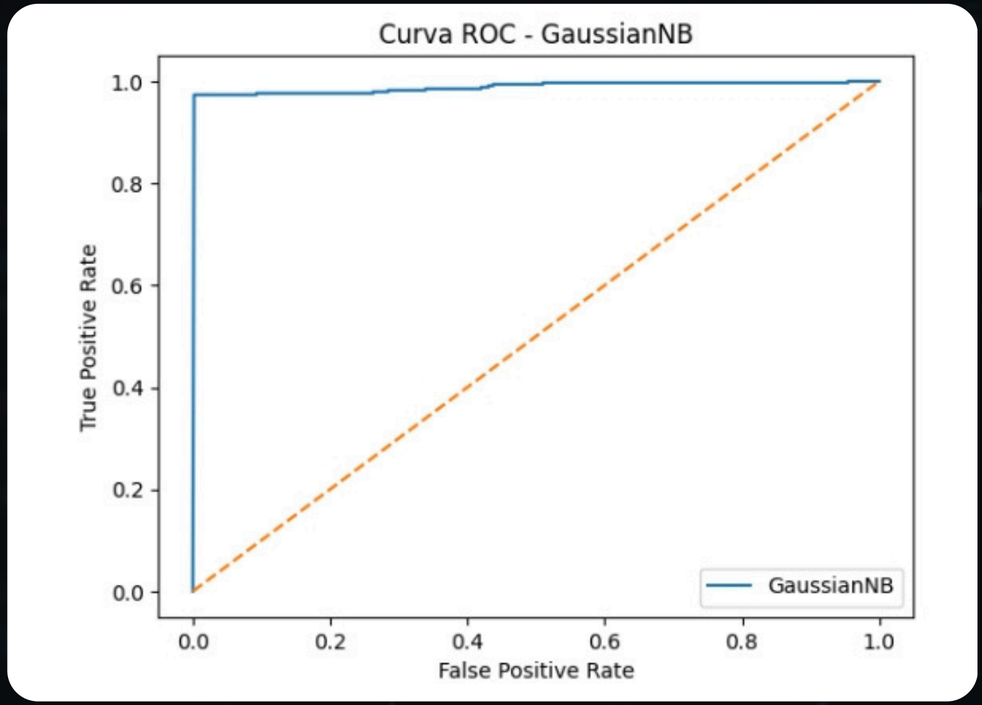

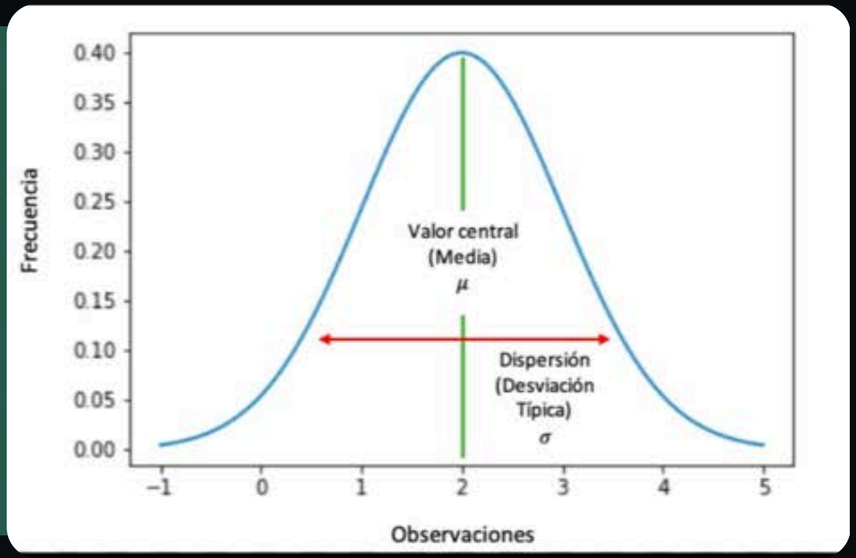

PROBLEMA DEL MODELO GAUSSIANO

Limitación de Gaussian Naive Bayes

Asume:

Distribuciones normales

Pero en datasets reales:

Las variables no siempre son gaussianas

Solución:

Kernel Density Estimation

KDE

Kernel Density Estimation (KDE)

Permite:

- Estimar densidades de probabilidad
- Sin asumir distribución específica

Modelos evaluados:

- KDE Gaussiano
- KDE Silverman
- KDE Parzen

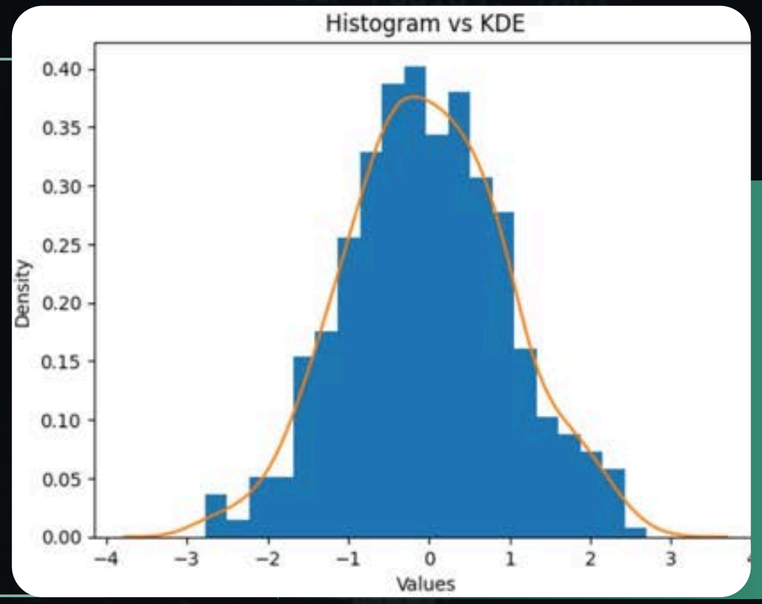

RESULTADOS

COMPARACIÓN DE MODELOS

GAUSSIANNB → 0.985
KDE GAUSSIANO → 0.991
KDE SILVERMAN → 0.991
KDE PARZEN → 0.996

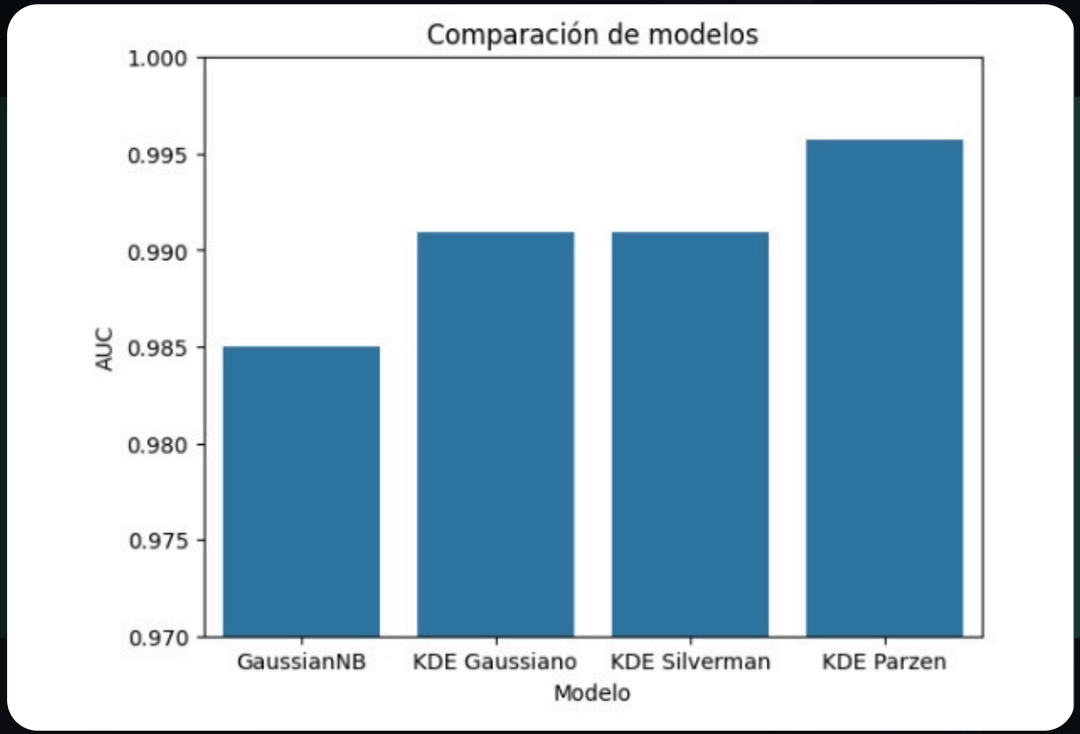

CONCLUSIÓN

- KDE mejora el desempeño del modelo
- GaussianNB funciona bien como baseline
- El mejor modelo fue KDE Parzen

Resultado final:
AUC ≈ 0.996

THANK YOU